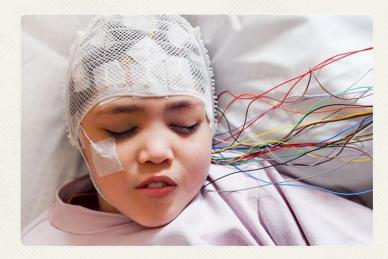
# AUTOMATIZACIÓN DEL PROCESO DE ANOTACIÓN DE SEÑALES EEG DE PACIENTES CON EPILEPSIA POR MEDIO DE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO



### **RESUMEN**

- Se tiene de objetivo el diseñar y crear una herramienta que emplee aprendizaje automático para identificar y anotar registros EEG.
- Se empleó Matlab 2019a y los conocimientos de los doctores de HUMANA para su desarrollo.
- Se obtuvo una interfaz validada con los doctores, que cuenta con la capacidad de crear algoritmos y de generar las anotaciones automáticamente.



[1]

## - OBJETIVOS

### **OBJETIVO GENERAL**



Desarrollar y validar un proceso de reconocimiento y anotación de posibles episodios ictales en señales electroencefalográficas (EEG) de pacientes con epilepsia, por medio de técnicas de aprendizaje automático.

### **OBJETIVOS ESPECÍFICOS**

- 1. Adaptar la herramienta de software desarrollada en la fase previa para el reconocimiento de señales EEG con registros ictales de pacientes de HUMANA.
- 2. Identificar automáticamente segmentos de interés dentro de las señales, de acuerdo a parámetros utilizados por el personal de HUMANA.

### **OBJETIVOS ESPECÍFICOS**

- 3. Generar automáticamente archivos con anotaciones relevantes para los segmentos de interés identificados.
- 4. Validar los segmentos de interés y las anotaciones con especialistas de HUMANA.

# - INTRODUCCIÓN

### **INTRODUCCIÓN**

### **EPILEPSIA**

¿Qué es la epilepsia y cuál es su relevancia en Guatemala?

### **EEG**

¿Qué son los EEG y para qué sirven en el diagnóstico de la epilepsia?

### **ANOTACIONES**

¿Qué son las anotaciones dentro del contexto de un registro de EEG?

# PROCESAMIENTO DE UN EEG

Actualmente, ¿cómo se procesan los EEG con computadoras?

# **APRENDIZAJE AUTOMÁTICO**

¿Qué puede hacer el aprendizaje automático para el procesamiento de los EEG?



### **EEG Y LA EPILEPSIA**

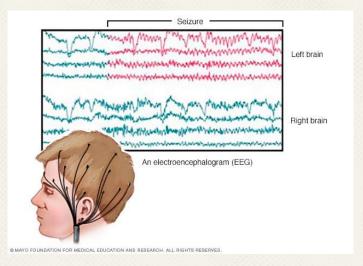
- Enfermedad que afecta el sistema nervioso.
- Se presenta de distintas formas y su diagnóstico se realiza con estudios clínicos.
- En Guatemala, se estiman 325,000 casos (HUMANA, 2015).



[3]

### **EEG Y LA EPILEPSIA**

- Un EEG es un registro de la actividad eléctrica del cerebro.
- Este se obtiene por medio de la colocación de electrodos en la cabeza.
- Relación entre ambos: herramienta de apoyo de diagnóstico.



[5]

# ANOTACIONES EN UN EEG

### **ANOTACIONES EN UN EEG**

- Son registros escritos relevantes en el diagnóstico.
- Se centran en segmentos relevantes del registro.
- Realizadas manualmente por un especialista.
- Las anotaciones pueden ser de registros de 24 horas.



### **ANOTACIONES EN UN EEG**

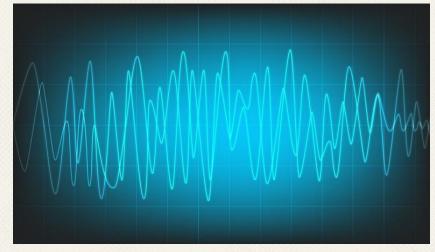
- Es crucial que un especialista realice la revisión.
- Se pueden anotar distintos elementos de interés.



PROCESAMIENTO
DE EEG Y
APRENDIZAJE
AUTOMÁTICO

### PROCESAMIENTO DE UN EEG

- Los EEG son de origen bioeléctrico, se requieren filtrar.
- Es posible segmentar un EEG en ventanas de menor tiempo.
- Su naturaleza no estacionaria hace que métodos como la transformada de Fourier no sean recomendados (Blanco et al. 1996)
- Se recomienda usar datos extraídos en tiempo continuo o de la señal transformada en tiempo-frecuencia (Wavelet).



### **APRENDIZAJE AUTOMÁTICO**

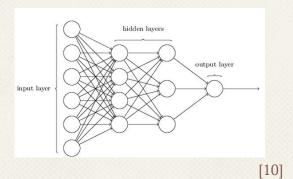
- Es el proceso por el cuál un algoritmo desarrolla la capacidad de aprender un patrón.
- Se divide en tres ramas significativas: supervisado, no supervisado y reforzado.
- Para los algoritmos se requiere tener las características distintivas de las clases a discernir.
- Lo anterior permite el uso de estas técnicas para procesar un EEG.

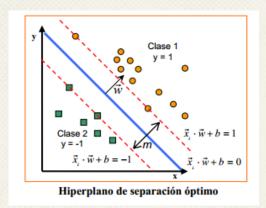


[9]

### **APRENDIZAJE AUTOMÁTICO**

- Las RNA son algoritmos que toman de base el principio de funcionamiento del cerebro: las neuronas.
- Los SVM emplean hiperplanos para realizar clasificaciones binarias.

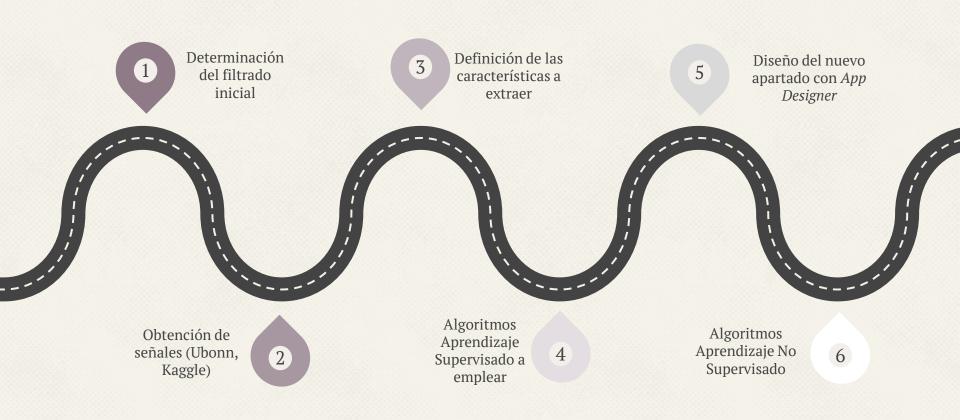




[11]

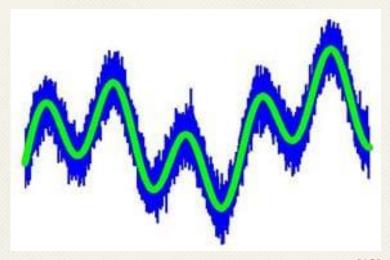
# DISEÑO - EXPERIMENTAL

### **DISEÑO EXPERIMENTAL**



### FILTRO INICIAL A EMPLEAR

- Filtrar en exceso un EEG hace que este pierda información.
- Se contrastaron tres filtros: Wiener, Butterworth y Chebyshev (Gonzales, 2014).
- Se empleó un segmento de 10 segundos de un EEG y una señal sinusoidal de 100Hz como ruido.



[12]

### **OBTENCIÓN DE LAS SEÑALES**

- Para el entrenamiento, se requieren registros con etiquetas conocidas.
- Los conjuntos de la Universidad de Bonn y del concurso de predicción de epilepsia de la American Epilepsy Society Seizure Prediction completan los tipos de señales requeridos.



[14]

### **CARACTERÍSTICAS A EXTRAER**

- La delimitación de las características relevantes se hace en base a trabajos previos.
- Las características en tiempo continuo y en el dominio tiempofrecuencia son útiles para discernir entre señales.
- Se realizó una segmentación en ventanas de un segundo.



[15]

### ALGORITMOS DE APRENDIZAJE SUPERVISADO

- Para la clasificación se emplearon las redes neuronales (RNA) y la máquina de vectores de soporte (SVM).
- Se adaptó la programación para poder trabajar con una cantidad variable de clases.
- Para la RNA se realiza el entrenamiento con sets de entrenamiento, validación y prueba, para la SVM se realiza con validación cruzada.



[16]

### **DISEÑO NUEVA INTERFAZ**

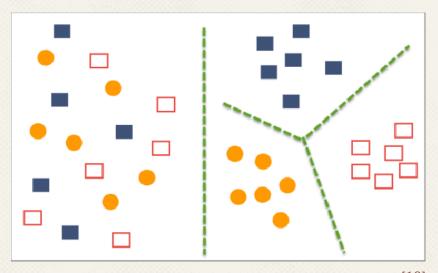
- Se requiere una interfaz visual para los usuarios.
- La nueva sección se creó con la herramienta de App Designer de Matlab 2019a.
- Dentro de esta interfaz se permite la creación del algoritmo de aprendizaje supervisado y la revisión de la señal con anotaciones visuales.



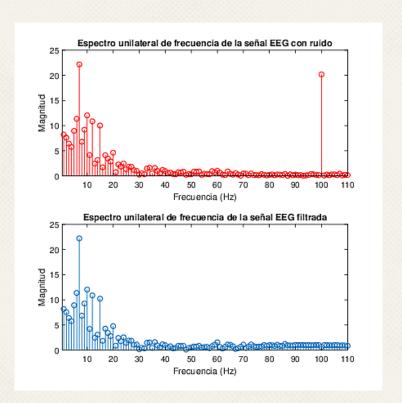
[17]

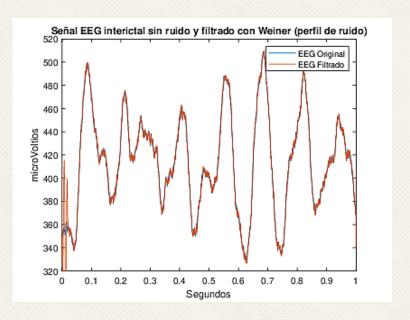
# ALGORITMOS DE APRENDIZAJE NO SUPERVISADO

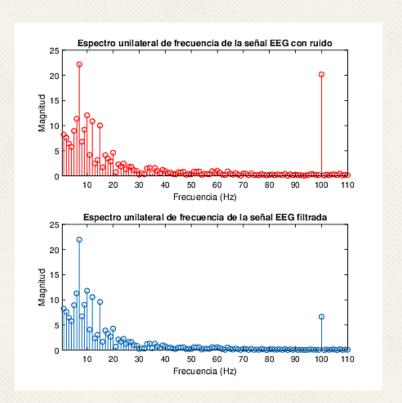
 Se creó el apartado dentro de la interfaz para poder cargar un vector de etiquetas generado con un algoritmo de aprendizaje no supervisado.

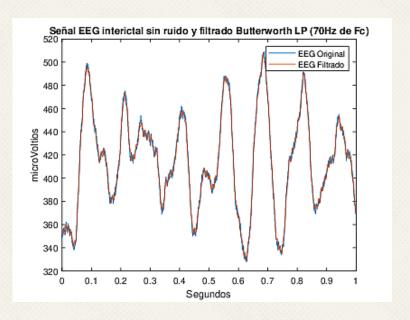


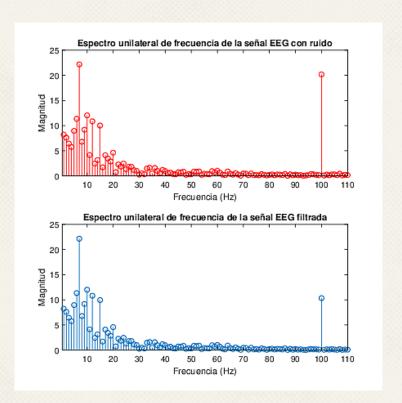
[18]

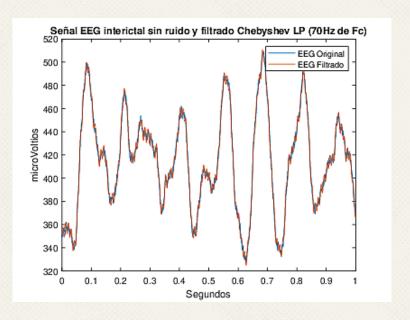












Matriz de confusión: SVM con características en tiempo continuo y kernel gaussiano								
Clase predicha	Ictal	25.0%	0.4%	0.0%	0.0%	98.4% 1.6%		
	Cana	0.0%	24.2%	0.0%	0.4%	98.3%		
	Sano	0.070	21,270	0.070	0.170	1.7%		
	Preictal	0.0%	0.4%	20.0%	2.5%	87.3% 12.7%		
	Interictal	0.0%	0.0%	5.0%	22.1%	81.5%		
	Interictal	31373	0.070	3,373		18.5%		
		100%	96.7%	80.0%	88.3%	91.3%		
		0.0%	3.3%	20.2%	11.7%	8.8%		
		Ictal	Sano	Preictal	Interictal	Exactitud		
		Clase Objetivo						

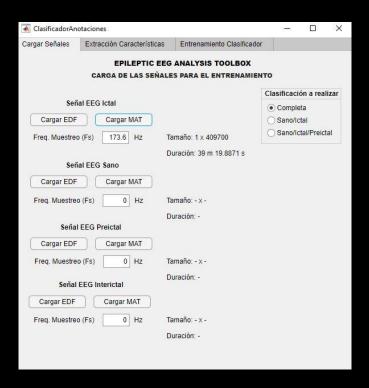
Características	Tiempo Continuo			Wavelet			
Modelo	RNA	SVM		RNA	SVM		
Kernel	-	Gaussiano	Lineal	-	Gaussiano	Lineal	
2 Clases	100.0%	99.8%	100.0%	97.7%	98.7%	97.9%	
3 Clases	97.9%	98.9%	97.2%	98.2%	98.3%	97.2%	
4 Clases	88.0%	91.3%	88.3%	81.2%	83.3%	77.1%	
Promedio	95.3%	96.7%	95.2%	92.4%	93.4%	90.7%	
Desv. Estándar	5.23%	3.81%	4.99%	7.90%	7.17%	9.64%	



### HERRAMIENTA PARA ANOTACIONES AUTOMÁTICAS

# CREACIÓN DEL ALGORITMO DE APRENDIZAJE SUPERVISADO

### **CARGA SEÑALES A EMPLEAR**





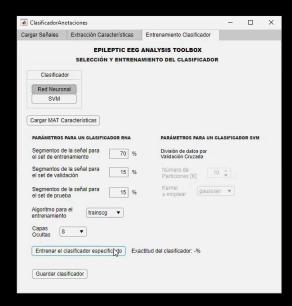
# SELECCIÓN CARACTERÍSTICAS A EXTRAER





# CREACIÓN DEL ALGORITMO CLASIFICADOR





# APARTADO DE ANOTACIONES AUTOMÁTICAS

## CARGA DE LA SEÑAL DE INTERÉS





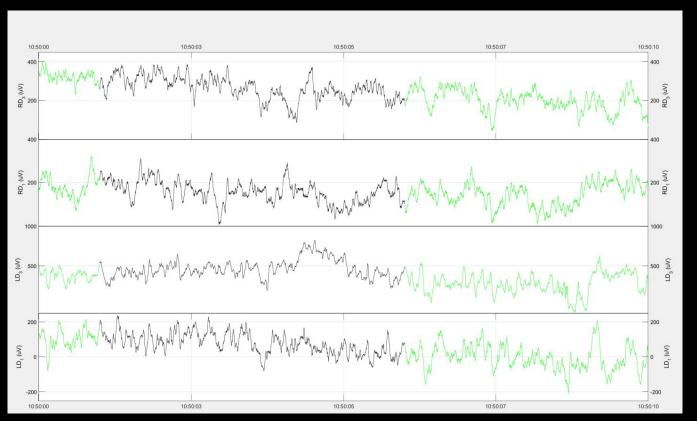




## **VISUALIZACIÓN DEL REGISTRO**



## GUARDADO DEL SEGMENTO DE INTERÉS



## - CONCLUSIONES

#### **CONCLUSIONES**

- 1. El clasificador con el mejor desempeño fue la máquina de vectores de soporte con características en tiempo continuo y kernel gaussiano, obteniendo un promedio de exactitud del 96.7% y una desviación estándar de los datos de 3.81%
- 2. El uso de características de Wavelet demuestra el intercambio entre exactitud y velocidad: no presentan los mejores resultados pero se extraen con menor tiempo.
- 3. Se extendió la capacidad de la herramienta previa, contando con hasta cuatro clases, la posibilidad de visualizar las señales y los resultados de los algoritmos de forma personalizable.
- 4. Se realizó una primera validación con los doctores de HUMANA para la funcionalidad del nuevo segmento generado para la herramienta.

## - RECOMENDACIONES

#### **RECOMENDACIONES**

- 1. Obtener una mayor cantidad de datos etiquetados por médico, con señales provenientes directamente de HUMANA.
- 2. Validar el etiquetado de la morfología por medio de aprendizaje automático no supervisado con los especialistas de HUMANA.
- 3. Integrar la nueva herramienta de bases de datos con la aplicación resultante de este trabajo.
- 4. Incluir más información de utilidad para los médicos dentro de los archivos generados.

- 1. Shabir, O. (2019). ¿Qué podemos aprender de EEG del paciente con epilepsia?. Extraído de: <a href="https://www.news-medical.net/health/What-Can-We-Learn-from-EEGs-of-Patients-with-Epilepsy-(Spanish).aspx">https://www.news-medical.net/health/What-Can-We-Learn-from-EEGs-of-Patients-with-Epilepsy-(Spanish).aspx</a>. Accedido: 28-12-2021.
- 2. Mayo Foundation. (2021). *Epilepsy*. Mayo Clinic. Extraído de: <a href="https://www.mayoclinic.org/diseases-conditions/epilepsy/diagnosis-treatment/drc-20350098">https://www.mayoclinic.org/diseases-conditions/epilepsy/diagnosis-treatment/drc-20350098</a>. Accedido: 15-12-2021.
- 3. Makati Medical Center. (2020). *What Does It Mean to Have Epilepsy?*. Extraído de: <a href="https://www.makatimed.net.ph/news-and-exhibits/news/what-does-it-mean-to-have-epilepsy">https://www.makatimed.net.ph/news-and-exhibits/news/what-does-it-mean-to-have-epilepsy</a>. Accedido: 29-12-2021.
- 4. HUMANA. (2015). *Epilepsia*. Extraído de: <a href="https://humanagt.org/epilepsia/">https://humanagt.org/epilepsia/</a>. Accedido: 02-05-2021.
- 5. Mayo Foundation. (2021). <a href="https://www.mayoclinic.org/es-es/tests-procedures/eeg/about/pac-20393875">https://www.mayoclinic.org/es-es/tests-procedures/eeg/about/pac-20393875</a>. Accedido: 30-12-2021.

- 6. Fármaco Salud. (2018). *Nueva herramienta para el diagnóstico del dolor neuropático localizado*. Extraído de: <a href="https://farmacosalud.com/presentada-diagnostic-tool-una-nueva-herramienta-para-el-diagnostico-del-dolor-neuropatico-localizado/">https://farmacosalud.com/presentada-diagnostico-tool-una-nueva-herramienta-para-el-diagnostico-del-dolor-neuropatico-localizado/</a>. Accedido: 29-12-2021.
- 7. Blanco, et al. (1996). Time-frecuency analysis of electroencephalogram series. II. Gabor and wavelet transforms. Physical ReviewE, Vol 54, No. 6, páginas 6661-6672
- 8. Stanford Online. (2013). *Digital Signal Processing*. Extraído de: <a href="https://online.stanford.edu/courses/ee264-digital-signal-processing">https://online.stanford.edu/courses/ee264-digital-signal-processing</a>. Accedido: 28-12-2021.
- 9. Signals IoT. (2018). *La diferencia entre Inteligencia Artificial, Aprendizaje Automático y Aprendizaje Profundo*. Extraído de: <a href="https://signalsiot.com/la-diferencia-entre-inteligencia-artificial-aprendizaje-automatico-y-aprendizaje-profundo/">https://signalsiot.com/la-diferencia-entre-inteligencia-artificial-aprendizaje-automatico-y-aprendizaje-profundo/</a>. Accedido: 17-12-2021.
- 10. Darlington, K. (2017). *La era de la inteligencia artificial (IA): Parte 2- Aprendizaje áutomático*. Extraído de: <a href="https://www.bbvaopenmind.com/tecnologia/inteligencia-artificial/la-era-de-la-inteligencia-artificial-ia-parte-2-aprendizaje-automatico/">https://www.bbvaopenmind.com/tecnologia/inteligencia-artificial/la-era-de-la-inteligencia-artificial-ia-parte-2-aprendizaje-automatico/</a>. Accedido: 23-12-2021.

- 11. Gonzáles, S. (2014). *Detección de Anomalías Cardíacas con Aprendizaje Automático (Machine Learning*). Extraído de: <a href="http://samuelabad1991.blogspot.com/2014/02/analisis-con-maquinas-de-vectores.html">http://samuelabad1991.blogspot.com/2014/02/analisis-con-maquinas-de-vectores.html</a>. Accedido: 02-01-2022.
- 12. Teach Engineering. (2018). *Filtering: Extracting What We Want From What We Have*. Extraído de: <a href="https://www.teachengineering.org/lessons/view/csm\_filtering\_lesson01">https://www.teachengineering.org/lessons/view/csm\_filtering\_lesson01</a>. Accedido: 28-12-2021.
- 13. González J. (2014). *Filtrado Básico de Señales Biomédicas*. Extraído de: <a href="https://www.researchgate.net/publication/271273652\_Filtrado\_Basico\_de\_Senales\_Biomedicas">https://www.researchgate.net/publication/271273652\_Filtrado\_Basico\_de\_Senales\_Biomedicas</a>. Accedido: 25-05-2021.
- 14. Kirkland, E. (2019). *Increasing Kaggle Revenue: Analyzing user data to recommend the best new product*. <a href="https://towardsdatascience.com/increasing-kaggle-revenue-analyzing-user-data-to-recommend-the-best-new-product-f93fddbb4e0f">https://towardsdatascience.com/increasing-kaggle-revenue-analyzing-user-data-to-recommend-the-best-new-product-f93fddbb4e0f</a>. Accedido: 29-12-2021.

- 15. Quichimbo, N. (2018). *Estadística Descriptiva*. Extraído de: <a href="https://www.oas.org/ext/es/desarrollo/recursos-educacion-docente/Planes-de-Clase/Detalles/ArtMID/2250/ArticleID/663/-Estad-stica-Descriptiva">https://www.oas.org/ext/es/desarrollo/recursos-educacion-docente/Planes-de-Clase/Detalles/ArtMID/2250/ArticleID/663/-Estad-stica-Descriptiva</a>. Accedido: 04-01-2022.
- 16. Azteca Noticias. (2019). *Machine learning, la herramienta predictiva de hoy*. Extraído de: <a href="https://www.tvazteca.com/aztecanoticias/salud-educacion-y-bienestar/ciencia-y-salud/notas/machine-learning-la-herramienta-predictiva-de-hoy">https://www.tvazteca.com/aztecanoticias/salud-educacion-y-bienestar/ciencia-y-salud/notas/machine-learning-la-herramienta-predictiva-de-hoy</a>. Accedido: 02-01-2022.
- 17. Workana. (2020). ¿Qué es User Interface (UI)?. Extraído de: <a href="https://i.workana.com/glosario/que-es-user-interface-ui/">https://i.workana.com/glosario/que-es-user-interface-ui/</a>. Accedido: 02-01-2022.
- 18. Farias, A. (2020). *Data Mining and Machine Learning in Earth Observation An Application for Tracking Historical Algal Blooms*. Extraído de: <a href="https://www.researchgate.net/figure/An-example-of-clustering\_fig1\_343212147">https://www.researchgate.net/figure/An-example-of-clustering\_fig1\_343212147</a>. Accedido: 04-01-2022.